Analisi della compliance osservata

Proporzioni, intervalli di Wilson, forest plot e confronti multipli

Guida metodologica e operativa per Stata 19

25 ottobre 2026 — revisione operativa

Sommario

L'obiettivo applicativo è valutare la compliance all'igiene delle mani come indicatore della qualità del processo assistenziale, individuando possibili criticità dei reparti e orientando approfondimenti e interventi correttivi. Questa dispensa documenta due moduli Stata, derivati da `wilson_forest_v5.do` e `confronti_compliance_v2_5.do`, eseguiti da un unico programma principale. Si distinguono stima puntuale, incertezza della stima, test globale, confronti a coppie e controllo della molteplicità. Gli esempi numerici sono *dimostrativi*, non risultati dello studio clinico.

Indice

1 Quesito, unità statistica e struttura dei dati **2**

1.1 Dalla fotografia descrittiva alla decisione organizzativa . . . 2

2 Parte I: stima delle proporzioni e forest plot **3**

2.1 Perché Wilson e non Wald . . . 3

2.2 Procedura effettivamente usata nel do-file . . . 3

2.3 Un solo dataset da predisporre: il formato A . . . 3

2.4 Passaggio automatico A–B . . . 3

2.5 Lettura del forest plot . . . 4

3 Parte II: confronto tra gruppi **4**

3.1 Test globale di Pearson . . . 4

3.2 Differenza assoluta tra proporzioni . . . 5

3.3 IC di Newcombe–Wilson: metodo 10 . . . 5

3.4 Test z pooled per la singola coppia . . . 5

4 Confronti multipli: Holm e Benjamini–Hochberg **5**

4.1 La famiglia dei confronti . . . 5

4.2 Holm: controllo del family-wise error rate . . . 6

4.3 Benjamini–Hochberg: controllo del false discovery rate . . . 6

4.4 Come interpretare i tre p-value . . . 6

5 Esecuzione integrata: un solo comando **6**

5.1 I tre do-file e le dipendenze 6

5.2 File prodotti e protezione contro la sovrascrittura 7

5.3 Controlli e contenuto del risultato inferenziale 7

6 Esempio dimostrativo e interpretazione **7**

7 Collaudi e limiti dell'inferenza **7**

7.1 Dipendenza non osservata e obiettivo della valutazione 8

7.2 Altri limiti e cautele 8

8 Schema per il resoconto scientifico **8**

Bibliografia **9**

1 Quesito, unità statistica e struttura dei dati

In una valutazione della qualità dell'assistenza, il reparto è l'unità organizzativa oggetto del confronto e l'occasione di igiene delle mani è l'unità di rilevazione. Non è necessario studiare il comportamento dei singoli operatori per calcolare la compliance globale del reparto. Per ciascun gruppo si rilevano il numero di occasioni in cui il comportamento è conforme (*successi*) e il numero totale di occasioni osservate. Un gruppo può essere una struttura, un'area medica/chirurgica o una categoria professionale. Il quesito descrittivo è «qual è la proporzione osservata di occasioni conformi?»; il quesito inferenziale è «le proporzioni differiscono tra gruppi?».

Per il gruppo i siano x_i i successi e n_i le occasioni, con $0 \leq x_i \leq n_i$ e $n_i > 0$. La proporzione campionaria è

$$\widehat{p}_i = \frac{x_i}{n_i}. \tag{1}$$

La forma di input consigliata è **una riga per gruppo**, con identificativo numerico univoco, nome testuale, x_i e n_i. Per esempio:

gruppo	localita	x	n	$\widehat{p}$
1	Bergamo	18	30	0,600
2	Genova	20	40	0,500
3	Firenze	7	25	0,280
4	Milano	30	40	0,750

Non ricostruire i successi da percentuali arrotondate quando i conteggi originali sono disponibili: l'arrotondamento può alterare le stime e i test. La forma aggregata è sufficiente per calcolare la compliance osservata, ma non permette di ricostruire possibili dipendenze fra occasioni appartenenti allo stesso operatore, turno o giornata.

1.1 Dalla fotografia descrittiva alla decisione organizzativa

Consideriamo due reparti: Medicina, con 70 comportamenti conformi su 100 occasioni, e Chirurgia, con 30 su 80. Le compliance *osservate* sono esattamente 70% e 37,5%; la differenza osservata è 32,5 punti percentuali. Questi tre numeri non cambiano se le occasioni riguardano molti operatori diversi oppure pochi operatori osservati ripetutamente. Per descrivere le occasioni effettivamente registrate non occorre alcuna ipotesi di indipendenza.

Se invece le occasioni osservate in determinati giorni e turni devono rappresentare la *compliance abituale* del reparto, entra in gioco l'incertezza campionaria. Gli intervalli di confidenza e i test richiedono ipotesi sul meccanismo di selezione e sulla dipendenza fra occasioni: osservazioni concentrate in uno stesso turno, per esempio, possono condividere condizioni organizzative comuni. La scelta casuale di giorni e turni, se effettivamente avvenuta, favorisce la rappresentatività ma non garantisce da sola l'indipendenza delle occasioni. Il disegno di campionamento effettivo va quindi verificato, ove possibile, con chi ha condotto la rilevazione.

Tre livelli distinti: (1) documentare la compliance osservata; (2) quantificare l'incertezza e confrontare i reparti, sotto ipotesi esplicite; (3) individuare criticità, indagarne le cause e verificare eventuali miglioramenti dopo interventi. Una compliance assoluta insoddisfacente può richiedere attenzione anche quando il confronto con altri reparti non è statisticamente significativo. I dati aggregati non consentono, da soli, di stabilire se le cause siano formazione, carichi di lavoro, disponibilità di dispositivi o altri fattori.

2 Parte I: stima delle proporzioni e forest plot

2.1 Perché Wilson e non Wald

Il consueto intervallo di Wald, $\widehat{p} \pm z_{1-\alpha/2}\sqrt{\widehat{p}(1-\widehat{p})/n}$, può avere copertura insoddisfacente, specialmente per campioni piccoli e proporzioni vicine a 0 o 1; inoltre può oltrepassare l'intervallo $[0,1]$. Per questo il programma utilizza l'intervallo *score* di Wilson [1].

Posto $z = z_{1-\alpha/2}$ e $\widehat{p} = x/n$, il centro e la semilarghezza dell'intervallo di Wilson sono

$$C = \frac{\widehat{p} + z^2/(2n)}{1 + z^2/n}, \tag{2}$$

$$H = \frac{z}{1 + z^2/n}\sqrt{\frac{\widehat{p}(1-\widehat{p})}{n} + \frac{z^2}{4n^2}}. \tag{3}$$

L'intervallo bilaterale è $[C - H, C + H]$; per il 95% si usa $z \simeq 1{,}96$. È definito anche per $x = 0$ e $x = n$, senza imporre intervalli di ampiezza nulla.

2.2 Procedura effettivamente usata nel do-file

Il modulo `wilson_forest_v5_pipeline.do` legge il dataset A con i *conteggi osservati* (`gruppo`, `localita`, `successi`, `numerosita`). Per ciascun gruppo applica:

```
quietly cii proportions `nn' `xx', wilson
```

Il calcolo di Wilson e la costruzione grafica rimangono quelli della versione v5 verificata. La revisione riguarda soltanto ingresso, uscita e collegamento tra moduli.

2.3 Un solo dataset da predisporre: il formato A

L'utente inserisce soltanto `file_A.dta`, con *una riga per reparto* e quattro variabili obbligatorie: identificativo numerico `gruppo`, denominazione testuale `localita`, numero di lavaggi conformi `successi` e totale delle occasioni `numerosita`. Si utilizzano **conteggi effettivi**, non conteggi ricostruiti da percentuali arrotondate. Per esempio:

```
clear
input byte gruppo str35 localita long successi long numerosita
1 "Medicina"  70 100
2 "Chirurgia" 30  80
end
save "file_A.dta"
```

Il file `crea_file_A_esempio.do`, incluso nel pacchetto, genera invece un esempio dimostrativo con dieci gruppi. Va eseguito *una sola volta* e non va confuso con i dati reali.

2.4 Passaggio automatico A–B

Il primo modulo crea `file_A_B.dta`, una riga per reparto, con `gruppo`, `localita`, `x` (successi) e `n` (occasioni). È questo il formato richiesto dal secondo modulo. Nel vecchio programma il cosiddetto "formato B" era invece una tabella *long* di successi/insuccessi, **non direttamente compatibile** con il do-file dei confronti: la revisione esplicita e risolve questa differenza. Il file A originale non viene riscritto.

2.5 Lettura del forest plot

Ogni riga mostra una proporzione stimata (simbolo) e il corrispondente IC di Wilson al 95% (segmento). L'asse orizzontale rappresenta la probabilità di successo, da 0 a 1; a destra sono riportati n, stima e limiti. La lunghezza dell'intervallo riflette l'incertezza *entro il singolo gruppo*; la sovrapposizione o non sovrapposizione di due IC individuali non sostituisce un test formale della differenza fra proporzioni. Gli IC sono nominali, non simultanei.

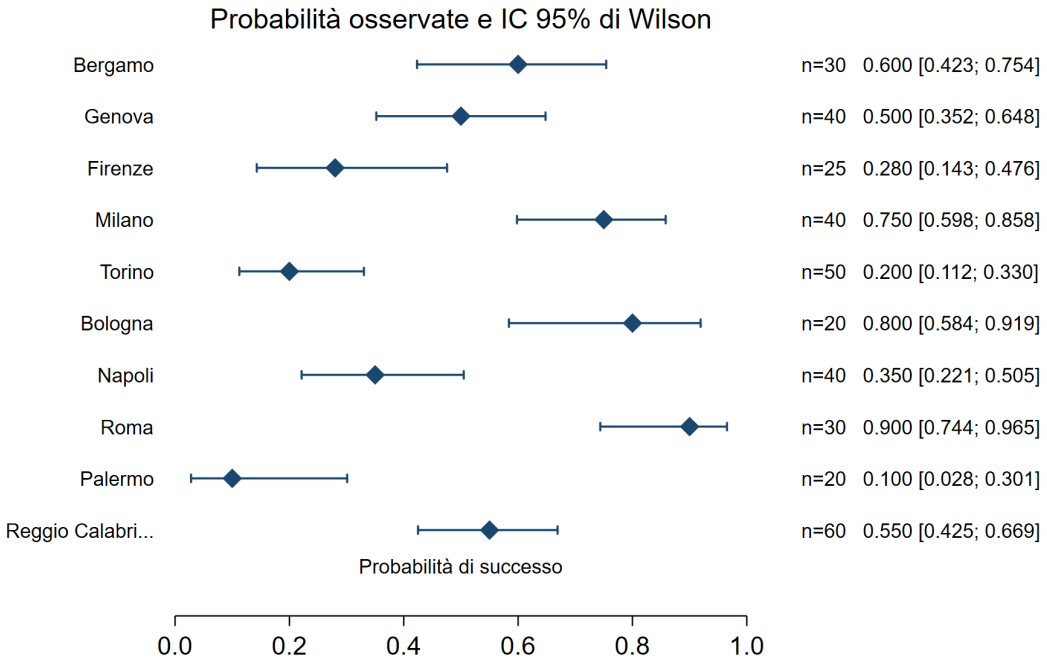


Figura 1: Esempio illustrativo di forest plot prodotto nel percorso di sviluppo; per i dati correnti utilizzare il file esportato dalla versione v5.

3 Parte II: confronto tra gruppi

3.1 Test globale di Pearson

Per K gruppi, si costruisce una tabella $K \times 2$ con successi e insuccessi. Il test omnibus valuta

$$H_0 : p_1 = p_2 = \cdots = p_K.$$

La statistica di Pearson è $\chi^2 = \sum_{i,j}(O_{ij} - E_{ij})^2/E_{ij}$, con $K - 1$ gradi di libertà se entrambe le categorie di esito sono presenti e valgono le usuali condizioni di approssimazione. Il test risponde alla domanda globale: *esiste evidenza di eterogeneità?* Non identifica da solo le coppie responsabili. Se tutte le occasioni sono successi o tutte sono insuccessi, il programma segnala che il chi-quadrato non è calcolabile.

Con frequenze attese molto piccole, l'approssimazione chi-quadrato può essere inadeguata; occorrono metodi appropriati alla dimensione e alla struttura dei dati. L'esecuzione senza errori di Stata non dimostra la validità dell'approssimazione.

3.2 Differenza assoluta tra proporzioni

Per la coppia ordinata (i, j) si stima la *risk difference* (RD), qui intesa come differenza assoluta di proporzioni:

$$\widehat{\mathrm{RD}}_{ij} = \widehat{p}_i - \widehat{p}_j. \tag{4}$$

Una RD di 0,20 equivale a 20 punti percentuali in più nel primo gruppo. Il segno dipende dall'ordine dei gruppi: il do-file li ordina secondo l'identificativo numerico e genera tutte le $M = K(K-1)/2$ coppie.

3.3 IC di Newcombe–Wilson: metodo 10

Per due proporzioni indipendenti, il programma richiama `newcombe11.ado` con l'opzione `method(10)`, corrispondente al metodo di Newcombe basato sui limiti score di Wilson senza correzione di continuità [2]. Siano $[L_i, U_i]$ e $[L_j, U_j]$ i rispettivi IC di Wilson. Posto $d = \widehat{p}_i - \widehat{p}_j$, i limiti della differenza sono

$$L_{ij} = d - \sqrt{(\widehat{p}_i - L_i)^2 + (U_j - \widehat{p}_j)^2}, \tag{5}$$

$$U_{ij} = d + \sqrt{(U_i - \widehat{p}_i)^2 + (\widehat{p}_j - L_j)^2}. \tag{6}$$

Questi sono **intervalli nominali al 95% per ciascuna differenza**, non una famiglia di intervalli con copertura simultanea del 95%. Il metodo presuppone due campioni indipendenti; la dipendenza tra occasioni può comprometterne la copertura.

3.4 Test z pooled per la singola coppia

Per $H_0 : p_i = p_j$ si utilizza la proporzione aggregata sotto l'ipotesi nulla,

$$\widehat{p}_0 = \frac{x_i + x_j}{n_i + n_j}, \qquad Z = \frac{\widehat{p}_i - \widehat{p}_j}{\sqrt{\widehat{p}_0(1-\widehat{p}_0)(1/n_i + 1/n_j)}}.$$

Il p-value bilaterale è $2\Phi(-|Z|)$. Se la varianza sotto H_0 è nulla perché entrambi i gruppi presentano lo stesso esito costante, il programma assegna $p = 1$. Per due gruppi e con le condizioni asintotiche appropriate, Z^2 coincide con il chi-quadrato di Pearson a un grado di libertà.

Precisazione: il test z pooled e l'IC Newcombe–Wilson non sono costruiti mediante inversione dello stesso identico test. Perciò l'esclusione dello zero da un IC nominale e il risultato del test possono non coincidere esattamente vicino alla soglia; inoltre i p-value corretti per molteplicità rispondono a un quesito diverso dagli IC nominali.

4 Confronti multipli: Holm e Benjamini–Hochberg

4.1 La famiglia dei confronti

Con K gruppi, i confronti a coppie sono $M = K(K-1)/2$. Già con 10 gruppi si effettuano 45 test. La famiglia dei confronti deve essere definita in base al quesito scientifico (ad esempio tutte le strutture, oppure tutte le professioni), *prima* di esaminare quali p-value risultino significativi. Una famiglia più ampia modifica la correzione.

4.2 Holm: controllo del family-wise error rate

Il *family-wise error rate* (FWER) è la probabilità di commettere almeno un falso rifiuto nella famiglia di ipotesi vere. Holm [3] ordina i p-value $p_{(1)} \leq \cdots \leq p_{(M)}$ e costruisce i valori aggiustati

$$\widetilde{p}_{(i)}^{\text{Holm}} = \min\left\{1, \max_{1\leq j\leq i}[(M-j+1)p_{(j)}]\right\}.$$

Il metodo controlla il FWER sotto ipotesi di validità dei singoli p-value, senza richiedere indipendenza tra i test. È una scelta prudente quando si vogliono contenere i falsi positivi nella famiglia.

4.3 Benjamini–Hochberg: controllo del false discovery rate

Il *false discovery rate* (FDR) è il valore atteso della quota di falsi rifiuti tra le ipotesi respinte, assumendo tale quota pari a zero quando non vi sono rifiuti. La procedura di Benjamini–Hochberg (BH) [4] produce

$$\widetilde{p}_{(i)}^{\text{BH}} = \min\left\{1, \min_{i\leq j\leq M} \frac{M}{j} p_{(j)}\right\}.$$

BH è spesso meno conservativa di Holm, ma le sue garanzie di controllo FDR richiedono specifiche condizioni sulla dipendenza dei p-value (tra cui indipendenza o forme ammissibili di dipendenza positiva). I confronti che condividono gruppi sono correlati; **non è garantito automaticamente** che la procedura soddisfi le sue condizioni nel caso concreto. Il programma riporta entrambi gli aggiustamenti, senza pretendere che siano intercambiabili.

4.4 Come interpretare i tre p-value

`p_raw` valuta la singola coppia senza correzione; `p_holm` e `p_bh` sono valori aggiustati rispetto all'intera famiglia. Le variabili `sig_holm` e `sig_bh` valgono 1 quando il corrispondente p-value aggiustato è al più 0,05. Il numero di confronti significativi *non* è una misura di grandezza dell'effetto clinico: per questo va sempre affiancato alla RD e al suo IC nominale.

5 Esecuzione integrata: un solo comando

5.1 I tre do-file e le dipendenze

La soluzione operativa utilizza `compliance_completa.do` come *programma principale*, che richiama in sequenza `wilson_forest_v5_pipeline.do` e `confronti_compliance_v2_5_pipeline.do`. I due moduli restano separati e verificabili; non è necessario copiare il secondo listato alla fine del primo. `newcombe11.ado` deve essere raggiungibile dall'`adopath`. Tutti i file vanno collocati nella cartella di lavoro impostata in Stata.

L'utente modifica soltanto, nel programma principale, il nome del dataset A:

```
local fileA "file_A.dta"
```

Poi esegue:

```
do "compliance_completa.do"
```

Il nome di B e quelli di tutti gli output sono derivati automaticamente da A. Non occorre modificare i moduli a ogni elaborazione.

5.2 File prodotti e protezione contro la sovrascrittura

Con `file_A.dta` come ingresso, la pipeline genera:

File	Contenuto
`file_A_B.dta`	Dati aggregati per i confronti
`file_A_wilson.dta`	Stime e IC di Wilson
`file_A_forest.png`	Forest plot
`file_A_B_confronti.dta`	Risultati completi delle coppie
`file_A_B_confronti.csv`	Esportazione dei confronti

Prima di cominciare, il programma principale verifica *tutti* i nomi degli output. Se ne esiste già uno, interrompe l'esecuzione senza cancellarlo. Anche i moduli non utilizzano `replace` per gli output permanenti. Per conservare analisi successive, archiviare i risultati o usare un diverso nome di dataset A, per esempio `reparti_20261115_A.dta`. Evitare di utilizzare il nome del dataset A per un output.

5.3 Controlli e contenuto del risultato inferenziale

Il modulo di confronto verifica identificativi univoci, numerosità intere positive e successi interi compresi tra zero e il totale. Restituisce il test globale di Pearson, le differenze assolute tra tutte le coppie, gli IC nominali Newcombe–Wilson e i p-value grezzi, Holm e BH. Le colonne temporanee `p_grezzo`, `p_Holm` e `p_BH` migliorano soltanto la stampa; i file esportati conservano i p-value numerici e gli indicatori `sig_holm`, `sig_bh`. Se i confronti sono più di 45, la stampa è abbreviata, ma l'esportazione resta completa.

Avvertenza: la pipeline è predisposta per Stata 19 e per il formato A descritto. La modifica gestionale non cambia le formule statistiche, ma la nuova integrazione deve essere collaudata in Stata prima dell'uso definitivo su dati reali.

6 Esempio dimostrativo e interpretazione

Nel dataset di dieci località si hanno $K = 10$ gruppi e $M = 45$ confronti. Il test globale fornisce $\chi^2(9) = 77{,}4378$ e $p < 0{,}000001$. Ai fini illustrativi, 18 confronti hanno $p_{\text{Holm}} \leq 0{,}05$ e 25 hanno $p_{\text{BH}} \leq 0{,}05$.

Per Bergamo (18/30) e Torino (10/50), $\widehat{p}_1 = 0{,}60$, $\widehat{p}_2 = 0{,}20$ e $\widehat{\text{RD}} = 0{,}40$: la compliance osservata è superiore di 40 punti percentuali nel primo gruppo. Nel file di esempio l'IC nominale di Newcombe è circa $[0{,}1803; 0{,}5772]$, con $p_{\text{raw}} \simeq 0{,}000282$, $p_{\text{Holm}} \simeq 0{,}009867$ e $p_{\text{BH}} \simeq 0{,}001153$. La grandezza dell'effetto, la sua incertezza nominale e le due decisioni corrette per molteplicità sono informazioni distinte.

Per Napoli rispetto a Reggio Calabria la RD è $-0{,}20$ e l'IC nominale è circa $[-0{,}3753; -0{,}0009]$, ma il p-value aggiustato BH è circa 0,074447. Non è una contraddizione: il primo è un IC nominale per un singolo confronto, il secondo è un p-value riferito alla famiglia dei 45 confronti. Non è corretto descrivere quell'IC come «corretto per BH».

7 Collaudi e limiti dell'inferenza

Il programma inferenziale è stato eseguito in Stata 19 con dieci gruppi e in collaudi separati con due gruppi, tre gruppi (proporzioni 0%, 50%, 100%), tutti successi, tutti insuccessi e numerosità

molto piccole. Nei casi con esito globalmente costante, il test omnibus è correttamente segnalato come non calcolabile, mentre le differenze osservate sono nulle e i test a coppie restituiscono $p = 1$. Si tratta di *collaudi di funzionamento*, non di una dimostrazione di accuratezza inferenziale in ogni condizione.

7.1 Dipendenza non osservata e obiettivo della valutazione

L'oggetto della valutazione è il **reparto nella sua globalità**, non il singolo operatore. La compliance osservata x/n resta un rapporto descrittivo esatto per le occasioni registrate, indipendentemente da chi le abbia generate. La possibile dipendenza diventa rilevante soltanto quando si impiegano IC e test per generalizzare dalle occasioni osservate al processo assistenziale abituale.

Occasioni osservate durante lo stesso turno o la stessa giornata possono risentire di condizioni comuni; inoltre lo stesso operatore può comparire più volte. In presenza di correlazione positiva, il numero di occasioni può sovrastimare l'informazione effettivamente disponibile: gli IC possono risultare troppo stretti e i p-value troppo piccoli. L'assenza di identificativi e di informazioni sul raggruppamento delle osservazioni impedisce di quantificare tale effetto e di costruire, in modo fondato, correzioni *cluster-robust*, modelli misti o equazioni di stima generalizzate (*generalized estimating equations*, GEE). Registrare queste informazioni in eventuali rilevazioni future sarebbe utile per la stima dell'incertezza, *non* per valutare individualmente gli operatori.

Non sappiamo con certezza come siano stati selezionati giorni, turni e occasioni; l'eventuale casualità del campionamento è un'ipotesi da verificare, non un fatto documentato. Holm e BH correggono il problema della molteplicità dei confronti, non l'eventuale dipendenza fra occasioni. I risultati inferenziali vanno quindi presentati come *condizionati alle ipotesi del modello*, distinguendoli dalle proporzioni descrittive osservate.

7.2 Altri limiti e cautele

Le differenze sono associazioni descrittive tra gruppi osservati, non automaticamente effetti causali. Composizione dei pazienti, tipo di occasione, turno e altre variabili possono differire tra gruppi. Le osservazioni aggregate non consentono un aggiustamento individuale. Con piccoli conteggi attesi i test asintotici richiedono cautela; gli IC nominali non forniscono copertura simultanea. Per analisi primarie con dipendenza importante occorre un disegno/raccolta dati adeguati, possibilmente registrando i raggruppamenti per turno, giornata e operatore, oltre alle covariate pertinenti, senza modificare l'obiettivo di valutazione a livello di reparto.

8 Schema per il resoconto scientifico

«La compliance è stata utilizzata come indicatore della qualità del processo assistenziale a livello di reparto ed è stata descritta come numero di occasioni conformi sul totale delle occasioni osservate, con intervalli di confidenza al 95% calcolati mediante il metodo score di Wilson. Le stime sono state rappresentate graficamente con un forest plot. Le differenze globali fra gruppi sono state valutate mediante il test chi-quadrato di Pearson; per i confronti a coppie sono state calcolate differenze assolute di proporzioni con intervalli nominali al 95% secondo Newcombe–Wilson (metodo 10) e p-value bilaterali mediante test z con proporzione pooled sotto l'ipotesi nulla. I p-value sono stati corretti per confronti multipli con Holm e Benjamini–Hochberg. Le proporzioni osservate descrivono esattamente le occasioni registrate; la generalizzazione inferenziale alla compliance abituale dei reparti è condizionata alle ipotesi di campionamento e indipendenza delle occasioni, non interamente verificabili con i dati aggregati disponibili. I confronti non identificano le cause delle eventuali criticità organizzative.»

Bibliografia

Riferimenti bibliografici

[1] Wilson EB. Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*. 1927;22(158):209–212.

[2] Newcombe RG. Interval estimation for the difference between independent proportions: comparison of eleven methods. *Statistics in Medicine*. 1998;17(8):873–890.

[3] Holm S. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*. 1979;6(2):65–70.

[4] Benjamini Y, Hochberg Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society, Series B*. 1995;57(1):289–300.