Intervalli di confidenza per la differenza tra due proporzioni indipendenti

Gli undici metodi di Newcombe (1998), il comando `newcombe11` e la sua verifica numerica

Dispensa metodologica e quaderno di validazione

24 ottobre 2026 — bozza di lavoro, versione 1

Sommario

Questa dispensa distingue tre questioni: la definizione statistica degli intervalli di confidenza per la differenza tra proporzioni binomiali indipendenti; la loro implementazione nel comando Stata `newcombe11` (alpha 0.6); e la verifica della probabilità effettiva di copertura. Riporta controlli riproducibili effettuati durante lo sviluppo, il confronto con la Tabella II di Newcombe (1998), la correzione pubblicata nel 1999 e quattro verifiche mirate dei risultati di copertura. Non si afferma di aver replicato integralmente l'esperimento sui 9.200 punti dello studio originale.

Indice

1 Il problema statistico **1**

2 Gli undici metodi confrontati da Newcombe **1**
2.1 Il metodo di Wald e i suoi limiti . . . 2
2.2 Costruzione di Newcombe mediante intervalli Wilson . . . 2
2.3 Che cosa significa "exact" per il metodo 8 . . . 2

3 Il comando Stata `newcombe11` **3**
3.1 Sintassi e risultati . . . 3
3.2 Troncamento degli estremi . . . 3

4 Validazione dell'implementazione **3**
4.1 Riproduzione della Tabella II . . . 3
4.2 Prove funzionali e stress test . . . 3

5 Probabilità effettiva di copertura **4**
5.1 Definizione e calcolo per enumerazione . . . 4
5.2 Studio pilota: una griglia limitata . . . 4

6 Confronto con Newcombe (1998) **5**
6.1 Il disegno della valutazione originale . . . 5
6.2 Minimi della Tabella III . . . 5
6.3 Quattro verifiche mirate delle coperture pubblicate . . . 5

7 Limiti della validazione e criteri per la versione 1.0 **5**

8 Riproducibilità e organizzazione dei materiali **6**

9 Conclusioni **6**

1 Il problema statistico

Consideriamo due campioni *indipendenti*, con numerosità fissate n_1, n_2 e numeri di successi X_1, X_2:

$$X_1 \sim \mathrm{Bin}(n_1, \pi_1), \qquad X_2 \sim \mathrm{Bin}(n_2, \pi_2), \qquad X_1 \perp X_2. \tag{1}$$

Il parametro d'interesse è $\Delta = \pi_1 - \pi_2 \in [-1, 1]$; la stima naturale è $\widehat{\Delta} = X_1/n_1 - X_2/n_2$. L'intervallo di confidenza è una procedura che associa ai possibili dati due estremi $L(X_1, X_2)$ e $U(X_1, X_2)$. Non è, nell'interpretazione frequentista, una probabilità attribuita al parametro già fissato.

Il problema presenta difficoltà assenti nell'approssimazione normale ordinaria: parametri vincolati, campioni piccoli, distribuzioni discrete e possibilità di osservare zero successi o zero insuccessi. Metodi differenti possono avere la stessa confidenza nominale e coperture effettive molto diverse.

2 Gli undici metodi confrontati da Newcombe

La numerazione segue [1]. La sigla CC significa *continuity correction*, correzione di continuità. La tabella è una classificazione, non un ordinamento assoluto di qualità.

N.	Denominazione	Famiglia / caratteristica
1	Wald	Approssimazione normale senza CC
2	Wald con CC	Approssimazione normale con CC
3	Haldane	Procedura asintotica modificata
4	Jeffreys–Perks	Procedura asintotica modificata
5	Mee	Inversione del test score
6	Miettinen–Nurminen	Score con correzione della varianza
7	Profilo di verosimiglianza	Inversione del rapporto di verosimiglianze
8	Tail area “exact”	Probabilità di coda con peso pieno ai pareggi
9	Tail area mid-p	Probabilità di coda con mezzo peso ai pareggi
10	Newcombe–Wilson	Combinazione geometrica di intervalli score di Wilson, senza CC
11	Newcombe–Wilson con CC	Come 10, con intervalli Wilson corretti

2.1 Il metodo di Wald e i suoi limiti

Con $\widehat{\pi}_i = X_i/n_i$, la forma usuale senza correzione è

$$\widehat{\Delta} \;\pm\; z_{1-\alpha/2}\sqrt{\frac{\widehat{\pi}_1(1-\widehat{\pi}_1)}{n_1} + \frac{\widehat{\pi}_2(1-\widehat{\pi}_2)}{n_2}}. \tag{2}$$

Se entrambe le proporzioni osservate sono estreme, la stima della varianza può annullarsi. Ne può derivare un intervallo di ampiezza nulla: un risultato computazionalmente coerente con la formula, ma statisticamente inadeguato. Non si deve confondere questo limite del metodo con un errore di programmazione.

2.2 Costruzione di Newcombe mediante intervalli Wilson

Siano $[\ell_1, u_1]$ e $[\ell_2, u_2]$ gli intervalli score di Wilson, ciascuno al livello $1-\alpha$, per le due proporzioni. Per una singola proporzione osservata $\widehat{\pi} = x/n$, l'intervallo Wilson non corretto ha estremi

$$\frac{\widehat{\pi} + z^2/(2n) \;\pm\; z\sqrt{\widehat{\pi}(1-\widehat{\pi})/n + z^2/(4n^2)}}{1 + z^2/n}, \qquad z = z_{1-\alpha/2}. \tag{3}$$

Newcombe costruisce l'intervallo per Δ come

$$L = \widehat{\Delta} - \sqrt{(\widehat{\pi}_1 - \ell_1)^2 + (u_2 - \widehat{\pi}_2)^2}, \tag{4}$$

$$U = \widehat{\Delta} + \sqrt{(u_1 - \widehat{\pi}_1)^2 + (\widehat{\pi}_2 - \ell_2)^2}. \tag{5}$$

Questa è la forma utilizzata dal metodo 10. Per il metodo 11 si applica la stessa costruzione ai limiti Wilson *con* correzione di continuità.

Precisazione filologica: erratum del 1999. Nell'articolo del 1998, per il metodo 10, Newcombe presentava due espressioni equivalenti per alcune quantità intermedie. Nel 1999 chiarì che *con la correzione di continuità* le due espressioni non sono equivalenti: nel metodo 11 vanno utilizzate soltanto le prime, ossia le due radici quadratiche appena riportate [2]. Il codice alpha 0.6 recepisce questa correzione.

2.3 Che cosa significa "exact" per il metodo 8

L'aggettivo *exact* si riferisce alla valutazione delle probabilità di coda attraverso una distribuzione discreta, anziché mediante una semplice approssimazione normale. Non implica che l'intervallo abbia copertura almeno pari a $1 - \alpha$ per ogni π_1, π_2. Newcombe stesso documenta una copertura minima del 94,24% in uno dei punti esaminati per intervalli nominali al 95%. La versione mid-p attribuisce mezzo peso ai pareggi e può ridurre la conservatività, a costo di una copertura minima potenzialmente inferiore.

3 Il comando Stata `newcombe11`

3.1 Sintassi e risultati

La versione esaminata è `0.6.0 experimental`, del 24 ottobre 2026. Le due modalità operative sono:

```
newcombe11 9 10 3 10, all
newcombe11 esito, by(gruppo) all
newcombe11 9 10 3 10, method(11) level(95)
```

La prima forma riceve successi e denominatori; la seconda richiede un esito binario e due gruppi. La differenza è sempre prima proporzione meno seconda proporzione; nella sintassi `by()`, il primo gruppo corrisponde al valore numerico inferiore della variabile di raggruppamento. Il metodo predefinito è il 10 e il livello predefinito è 95%.

Il programma restituisce `r(ci)`, matrice numerica 11×2 con colonne `lb` e `ub`, oltre agli scalari `r(lb)`, `r(ub)`, `r(diff)`, `r(p1)`, `r(p2)`, `r(x1)`, `r(n1)`, `r(x2)`, `r(n2)`, `r(level)` e `r(method)`. I metodi 8 e 9 sono calcolati soltanto quando $(n_1 + 1)(n_2 + 1) \leq 10\,000$; altrimenti i relativi estremi risultano mancanti, mentre gli altri metodi rimangono disponibili.

3.2 Troncamento degli estremi

L'intervallo del parametro è $[-1, 1]$. Nell'implementazione verificata, gli estremi dei metodi asintotici che oltrepassano tali limiti vengono troncati. Questa scelta spiega alcune differenze di presentazione rispetto agli estremi non troncati della Tabella II; non costituisce una discrepanza algoritmica da nascondere.

4 Validazione dell'implementazione

4.1 Riproduzione della Tabella II

Sono stati riprodotti gli undici intervalli per ciascuno degli otto esempi della Tabella II di [1]: $8 \times 11 = 88$ intervalli, con accordo a quattro decimali, tenendo presente la convenzione di troncamento appena descritta. Gli otto esempi sono: 56/70 contro 48/80; 9/10 contro 3/10; 6/7 contro 2/7; 5/56 contro 0/29; 0/10 contro 0/20; 0/10 contro 0/10; 10/10 contro 0/20; 10/10 contro 0/10.

4.2 Prove funzionali e stress test

Il primo do-file di robustezza ha verificato l'inversione dei gruppi in quattro configurazioni per tutti gli undici metodi: 44 confronti entro la tolleranza 10^{-6}. È stata inoltre verificata la non diminuzione dell'ampiezza degli intervalli al crescere del livello di confidenza, per una configurazione, e l'equivalenza numerica fra sintassi immediata e `by()` (massima differenza osservata: zero). Il comando ha rifiutato successi superiori al denominatore con codice `r(198)`.

Una seconda batteria ha esaminato 30 configurazioni casuali e 10 configurazioni limite: **nessuna anomalia registrata** nei controlli previsti. In sei configurazioni è stato controllato anche l'annidamento degli intervalli al 90%, 95% e 99%. I controlli non rappresentano una prova formale di correttezza per tutti gli input possibili.

Tabella 1: Tempi osservati in Stata 19 per l'esecuzione completa dei metodi (singola misura per dimensione).

$n_1 = n_2$	5	10	20	40	60	80
Secondi	0,184	0,177	0,220	0,491	1,008	1,514

Le misure comprendono l'intero comando; non isolano il costo dei metodi 8 e 9 e non sono medie su ripetizioni.

5 Probabilità effettiva di copertura

5.1 Definizione e calcolo per enumerazione

Per π_1, π_2 fissati, la probabilità di copertura del metodo j è

$$\mathrm{CP}_j(\pi_1, \pi_2; n_1, n_2) = \Pr_{\pi_1,\pi_2}\{L_j(X_1, X_2) \le \Delta \le U_j(X_1, X_2)\} \tag{6}$$

$$= \sum_{a=0}^{n_1} \sum_{b=0}^{n_2} \mathbf{1}\{L_j(a,b) \le \Delta \le U_j(a,b)\} \binom{n_1}{a} \pi_1^a (1-\pi_1)^{n_1-a} \binom{n_2}{b} \pi_2^b (1-\pi_2)^{n_2-b}. \tag{7}$$

Questa somma valuta la copertura *esattamente rispetto alla distribuzione campionaria*, salvo arrotondamenti numerici e tolleranze dell'implementazione. Non è una simulazione Monte Carlo. Il termine "copertura esatta per enumerazione" descrive la modalità di *valutazione* della procedura e non coincide con il nome del metodo 8.

5.2 Studio pilota: una griglia limitata

Sono state considerate le 25 coppie $\pi_1, \pi_2 \in \{0{,}05; 0{,}20; 0{,}50; 0{,}80; 0{,}95\}$, dapprima con $n_1 = n_2 = 5$, poi con $n_1 = n_2 = 10$ e infine con $n_1 = 10, n_2 = 20$. Le coperture minime osservate sono riassunte di seguito; *non* rappresentano i minimi globali rispetto a tutte le probabilità possibili. La tabella rende visibile la sottocopertura del Wald in diversi scenari e la tendenza conservativa del metodo

Tabella 2: Copertura minima osservata (%) sulla griglia di 25 coppie, intervalli nominali al 95%.

Metodo	Nome sintetico	$5+5$	$10+10$	$10+20$
1	Wald	39,85	63,89	78,36
2	Wald CC	74,46	92,24	78,52
3	Haldane	73,38	88,54	87,76
4	Jeffreys–Perks	91,39	92,45	93,34
5	Mee	91,39	92,45	94,48
6	Miettinen–Nurminen	91,39	92,45	94,80
7	Profilo	85,98	89,87	89,05
8	Tail exact	97,03	95,78	95,72
9	Tail mid-p	93,95	93,69	93,88
10	Wilson	91,39	92,45	91,53
11	Wilson CC	94,70	93,71	94,86

8 sulla griglia prescelta. Non autorizza a classificare globalmente i metodi: la scelta della griglia influisce sui minimi osservati.

6 Confronto con Newcombe (1998)

6.1 Il disegno della valutazione originale

Newcombe ha selezionato 230 coppie di denominatori fra 5 e 50, comprendenti 46 coppie sulla diagonale $n_1 = n_2$ e 184 coppie fuori diagonale, scelte in modo da rappresentare caratteristiche rilevanti dell'insieme possibile. Per ciascuna coppia ha considerato 40 punti nello spazio parametrico, ottenendo $230 \times 40 = 9\,200$ configurazioni. La parametrizzazione dell'articolo è

$$\theta = \pi_1 - \pi_2, \qquad \psi = (\pi_1 + \pi_2)/2, \qquad \pi_1 = \psi + \theta/2, \quad \pi_2 = \psi - \theta/2. \tag{8}$$

I parametri sono generati nel dominio ammissibile, con $\theta = j[1 - |2\psi - 1|]$ e j, ψ estratti uniformemente in $(0, 1)$ per la valutazione principale. La Tabella III riporta statistiche riassuntive su *questi* punti: non è direttamente confrontabile con i minimi della nostra piccola griglia.

6.2 Minimi della Tabella III

Tabella 3: Minima copertura al 95% riportata nella Tabella III di Newcombe (1998), su 9.200 punti.

Metodo	1	2	3	4	5	6	7	8	9	10	11
Minimo (%)	0,04	51,37	0,35	85,05	85,16	85,16	82,99	94,24	91,31	86,73	93,39

Il metodo 8 non risulta strettamente conservativo nemmeno nello studio originale: il suo minimo osservato è 94,24%. Il metodo 10, pur essendo computazionalmente semplice e complessivamente valido, presenta anch'esso configurazioni di sottocopertura. Le proprietà di copertura vanno dunque valutate sull'intero spazio dei parametri, non da un singolo esempio.

6.3 Quattro verifiche mirate delle coperture pubblicate

Il programma Python, distinto dall'implementazione Mata/Stata, ha ricalcolato le coperture per quattro configurazioni critiche indicate nel testo originale. I parametri pubblicati sono arrotondati a quattro decimali; questo impedisce di richiedere coincidenza numerica perfetta. I valori di θ utilizzati sono rispettivamente 0,4016; 0,4705; 0,9645; 0,9233. Le differenze assolute rispetto ai valori pubblicati sono, nell'ordine, circa $9{,}1 \times 10^{-6}$, $3{,}3 \times 10^{-5}$, $2{,}59 \times 10^{-4}$ e $2{,}4 \times 10^{-6}$. Per

Tabella 4: Confronto tra valori pubblicati e enumerazione Python (coperture in scala 0–1).

Metodo	n_1	n_2	ψ	Newcombe	Python
8	32	25	0,2640	0,9424	0,942391
9	8	8	0,4890	0,9131	0,913133
10	35	15	0,5087	0,8673	0,867041
11	8	8	0,5160	0,9339	0,933898

il metodo 10 la differenza maggiore è plausibilmente legata all'arrotondamento dei parametri originari: è una spiegazione ragionevole, non una dimostrazione.

7 Limiti della validazione e criteri per la versione 1.0

I risultati raccolti supportano la decisione operativa di *congelare* gli algoritmi della alpha 0.6. Restano però limiti espliciti:

1. I controlli della Tabella II riguardano otto configurazioni, non l'intero dominio degli input.
2. Gli stress test casuali e limite non garantiscono l'assenza di errori in condizioni non esaminate.
3. Il programma Python è un'implementazione distinta, ma non una dimostrazione formale indipendente delle formule.
4. Non è stata replicata l'intera valutazione sui 9.200 punti di Newcombe.
5. Il vincolo $(n_1 + 1)(n_2 + 1) \leq 10\,000$ rende indisponibili i metodi 8 e 9 per campioni più grandi; non è una proprietà teorica degli intervalli.
6. La documentazione `.sthlp` inclusa nel pacchetto alpha 0.6 contiene ancora riferimenti a versioni precedenti e va aggiornata prima del rilascio 1.0.

Si propone di conservare un archivio intoccabile dell'ado alpha 0.6 e dei log di verifica. Ogni futura modifica agli algoritmi dovrà comportare la ripetizione della batteria di test. La promozione alla versione 1.0 può riguardare soltanto la documentazione e i messaggi di interfaccia, purché i risultati numerici rimangano invariati.

8 Riproducibilità e organizzazione dei materiali

I materiali di lavoro comprendono: `newcombe11.ado` e `newcombe11.sthlp`; il do-file per la Tabella II; `verify_newcombe11_robustezza.do`; `verify_newcombe11_stress.do`; i rispettivi log e CSV; `newcombe11_copertura_esatta_esteso.py`; e `verifica_newcombe_tabellaIII.py`. I risultati della verifica mirata sono registrati in `newcombe11_verifica_tabellaIII.csv`. Per evitare modifiche involontarie, gli originali e le copie congelate vanno conservati separatamente dai file di sviluppo.

9 Conclusioni

L'esperienza mette in evidenza tre livelli distinti di validazione: concordanza con esempi pubblicati, stabilità computazionale e verifica delle proprietà statistiche sotto campionamento ripetuto. Nessuno dei tre sostituisce gli altri. Nel caso in esame, i risultati sostengono la conservazione dell'implementazione alpha 0.6 come base stabile; le coperture calcolate confermano che una procedura nominalmente al 95% può sottocoprire anche in modo marcato. Per applicazioni ordinarie, i metodi 10 e 11 offrono una combinazione di semplicità e buone proprietà, pur senza

una garanzia universale di copertura nominale; la scelta resta subordinata al contesto e alla numerosità.

Riferimenti bibliografici

[1] Newcombe RG. Interval estimation for the difference between independent proportions: comparison of eleven methods. *Statistics in Medicine*. 1998;17:873–890.

[2] Newcombe RG. Correction. *Statistics in Medicine*. 1999;18:1293.